

# Μηχανική Μάθηση - Τελική Εργασία

Όνοματεπώνυμο: Παπαδόπουλος Ελευθέριος

Email: [eleftherios.v.papadopoulos@gmail.com](mailto:eleftherios.v.papadopoulos@gmail.com) - [epapadoax@csd.auth.gr](mailto:epapadoax@csd.auth.gr)

## Αποδεικτικό Συμμετοχής

The screenshot shows a competition interface. On the left, a modal window displays a "New submission" message with the text "Woohoo, your submission was successful! Your submission score is 21.8164". Below this, a "Your submissions" section lists three entries:

User	Submission Time	Score	Rank	Action
YOU	3d 6h ago	21.8164	21.8164	Done
Skolix15	2d 6h ago	21.816	18.237	<a href="#">Share your work?</a>
thecarmo	3d 21h ago	22.166	17.119	

On the right, a sidebar titled "Submissions" provides navigation links and information about the competition's scoring and rules.

## 1. Εισαγωγή & Περιγραφή Προβλήματος

Σκοπός της παρούσας εργασίας ήταν η επίλυση ενός προβλήματος παλινδρόμησης (regression) που αφορά την πρόβλεψη της κατά κεφαλήν ημερήσιας δαπάνης των νοικοκυριών. Χρησιμοποιήθηκαν πραγματικά δεδομένα από την πλατφόρμα DrivenData (World Bank Poverty Prediction). Η ακριβής πρόβλεψη αυτών των δεικτών είναι κρίσιμη για τη χάραξη κοινωνικής πολιτικής σε αναπτυσσόμενες χώρες.

## 2. Επεξεργασία & Προετοιμασία Δεδομένων

Η προετοιμασία των δεδομένων αποτέλεσε το πιο χρονοβόρο κομμάτι, καθώς τα αρχικά αρχεία απαιτούσαν ενοποίηση και καθαρισμό. Τα βήματα που ακολουθήθηκαν ήταν:

- **Merge:** Έγινε συνένωση των χαρακτηριστικών (*train\_hh\_features*) με τη μεταβλητή στόχο (*train\_hh\_gt*) μέσω του κωδικού *hhid*.
- **Feature Selection:** Αφαιρέθηκαν στήλες που θεωρήθηκαν πλεονάζουσες ή που θα μπορούσαν να προκαλέσουν overfitting (όπως τα *hhid*, *com*, *survey\_id*, *weight*).

- **Handling Missing Values:** Χρησιμοποιήθηκε ο μέσος όρος για τη συμπλήρωση κενών τιμών σε αριθμητικά δεδομένα.
- **Encoding:** Μετατράπηκαν οι κατηγορικές μεταβλητές (Yes/No, Urban/Rural) σε αριθμητική μορφή (0/1). Για τις μεταβλητές με πολλά επίπεδα (π.χ. πηγή νερού), εφαρμόστηκε η μέθοδος factorize.

## 3. Ανάλυση Δεδομένων

### 1. Περιγραφή / Ερμηνεία Χαρακτηριστικών

Τα χαρακτηριστικά του dataset χωρίζονται σε θεματικές ενότητες που περιγράφουν το βιοτικό επίπεδο ενός νοικοκυριού:

- **Δημογραφικά:** Μεταβλητές όπως το hsizc (μέγεθος νοικοκυριού) και η ηλικία του αρχηγού (age), που δείχνουν τη σύνθεση και τις ανάγκες της οικογένειας.
- **Υποδομές:** Πρόσβαση σε ηλεκτρισμό (elect), νερό (water) και αποχέτευση (sewer), που αποτελούν άμεσους δείκτες διαβίωσης.
- **Οικονομικά/Απασχόληση:** Οι δαπάνες κοινής ωφέλειας (utl\_exp\_ppp17) και ο τομέας εργασίας (sector1d), που δείχνουν την οικονομική επιφάνεια.
- **Κατανάλωση:** Δυαδικοί δείκτες (consumedXXXX) που καταγράφουν αν το νοικοκυριό αγόρασε συγκεκριμένα τρόφιμα, αποκαλύπτοντας το διατροφικό προφίλ.

### 2. Περιγραφή Μεταβλητών & Ποιότητα

**Τύποι Μεταβλητών:** Έχουμε ένα μείγμα αριθμητικών (π.χ. utl\_exp\_ppp17, age) και κατηγορικών μεταβλητών. Οι κατηγορικές μετατράπηκαν σε αριθμητικές μέσω του clean\_data (mapping για binary και factorize για τις υπόλοιπες).

**Ποιότητα Δεδομένων:** Η στήλη sector1d παρουσίασε το μεγαλύτερο ποσοστό ελλειπουσών τιμών, πιθανώς λόγω ανεργίας, και συμπληρώθηκε με τον μέσο όρο μετά την κωδικοποίηση.

- Οι μεταβλητές κατανάλωσης είναι πολύ "καθαρές" με ελάχιστα κενά.
- Η μεταβλητή στόχος cons\_ppp17 έχει εύρος τιμών που απαιτεί προσοχή, καθώς οι πολύ υψηλές τιμές (outliers) μπορεί να επηρεάσουν το RMSE.

## 3. Σημαντικότητα των Χαρακτηριστικών

Βάσει της φύσης του προβλήματος και των στατιστικών των δεδομένων:

1. **utl\_exp\_ppp17 (Δαπάνες Κοινής Ωφέλειας):** Είναι ο ισχυρότερος "proxy" δείκτης για το συνολικό εισόδημα.

2. **educ\_max** (**Εκπαίδευση**): Υπάρχει άμεση γραμμική σχέση μεταξύ του μορφωτικού επιπέδου και της ικανότητας κατανάλωσης.
3. **hsizs** (**Μέγεθος Νοικοκυριού**): Σε αναπτυσσόμενες οικονομίες, τα πολύ μεγάλα νοικοκυριά συνδέονται στατιστικά με χαμηλότερη κατά κεφαλήν δαπάνη.
4. **consumed2600 / consumed4700**: Συγκεκριμένοι κωδικοί τροφίμων που θεωρούνται "πολυτελείας" ή "ελαστικής ζήτησης" λειτουργούν ως ισχυροί διαχωριστές μεταξύ φτωχών και μη φτωχών νοικοκυριών.

#### 4. Συσχετίσεις μεταξύ Χαρακτηριστικών

- Παρατηρείται ισχυρή συσχέτιση μεταξύ της μεταβλητής `urban` και της πρόσβασης σε δίκτυα (`elect, sewer`), καθώς οι υποδομές αυτές είναι πιο ανεπτυγμένες στις πόλεις.
- Υπάρχει αρνητική συσχέτιση μεταξύ του `hsizs` και της κατά κεφαλήν δαπάνης, επιβεβαιώνοντας ότι τα μεγάλα νοικοκυριά είναι πιο επιρρεπή στη φτώχεια.
- Οι δαπάνες κοινής ωφέλειας (`utl_exp_ppp17`) συσχετίζονται θετικά με το επίπεδο εκπαίδευσης (`educ_max`), δείχνοντας ότι η μόρφωση οδηγεί σε υψηλότερη κατανάλωση υπηρεσιών.

## 4. Μεθοδολογία & Εφαρμογή Αλγορίθμων

Υλοποιήθηκαν τέσσερα διαφορετικά μοντέλα για τη σύγκριση των αποτελεσμάτων:

### A. Μηχανική Μάθηση (Machine Learning)

1. **Ridge Regression**: Χρησιμοποιήθηκε ως baseline μοντέλο. Προσφέρει μια γραμμική προσέγγιση με ρύθμιση L2 για την αποφυγή πολυκορυφικότητας.
2. **Random Forest Regressor**: Ένα ensemble μοντέλο δέντρων απόφασης. Επιλέχθηκε για την ικανότητά του να χειρίζεται outliers και μη-γραμμικές σχέσεις χωρίς ιδιαίτερη ανάγκη για κανονικοποίηση.
3. **XGBoost Regressor**: Μοντέλο Gradient Boosting που εστιάζει στη διόρθωση των σφαλμάτων των προηγούμενων δέντρων. Αποδείχθηκε το πιο ισχυρό μοντέλο, πετυχαίνοντας το χαμηλότερο **RMSE** (Εφαρμόστηκε με 500 estimators και learning rate 0.05).

### B. Βαθιά Μάθηση (Deep Learning)

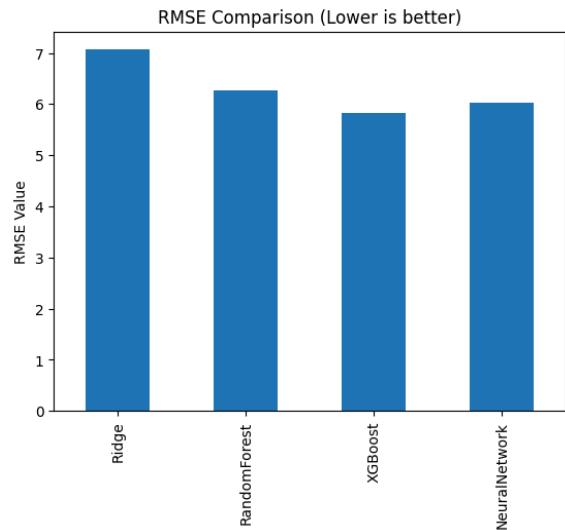
- **Multi-Layer Perceptron (MLP)**: Σχεδιάστηκε ένα νευρωνικό δίκτυο με 3 κρυφά επίπεδα (128, 64, 32 νευρώνες) και τεχνικές **Dropout** (0.2) για την αποφυγή υπερεκπαίδευσης. Το μοντέλο αυτό κατάφερε να συλλάβει σύνθετα μοτίβα στα δεδομένα κατανάλωσης.

## 5. Αποτελέσματα & Επικύρωση

Η αξιολόγηση έγινε στο validation set (20%) με βάση το σφάλμα **RMSE** (Root Mean Squared Error).

Μοντέλο	RMSE (Lower is better)	R <sup>2</sup> Score
Ridge	7.065	0.503
Random Forest	6.262	0.610
<b>XGBoost</b>	<b>5.819</b>	<b>0.663</b>
Neural Network	6.031	0.640

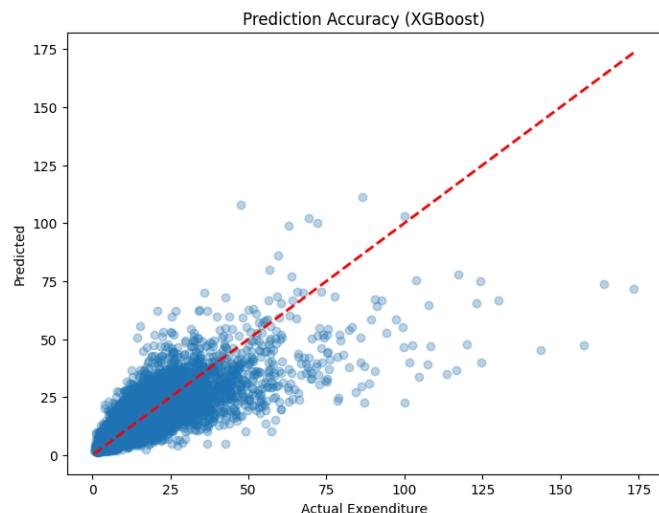
Το **XGBoost** αναδείχθηκε ως το βέλτιστο μοντέλο. Μετά το fine-tuning των υπερπαραμέτρων (learning rate, depth), χρησιμοποιήθηκε για την παραγωγή των τελικών προβλέψεων στο test set.



## 6. Επεξήγηση & Συμπεράσματα

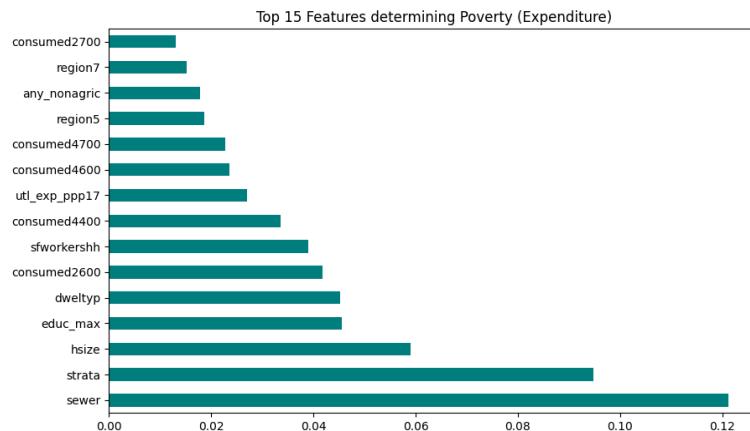
### Περιορισμοί Μοντέλων

Τα μοντέλα δυσκολεύονται να προβλέψουν πολύ υψηλές τιμές δαπανών, κάτι που φαίνεται στο γράφημα Actual vs Predicted, όπου οι προβλέψεις "συσσωρεύονται" γύρω από το κέντρο.



## Σημαντικότητα Χαρακτηριστικών

Το γράφημα Feature Importance του μοντέλου XGBoost δείχνει ότι την πρόβλεψη καθορίζουν κυρίως:



- **hsize (Μέγεθος Νοικοκυριού):** Περισσότερα μέλη → χαμηλότερη κατά κεφαλήν δαπάνη.
- **utl\_exp\_ppp17 (Δαπάνες Κοινής Ωφέλειας):** Υψηλότερες δαπάνες συνδέονται με καλύτερο βιοτικό επίπεδο.
- **strata (Στρώμα Δειγματοληψίας):** Αποτυπώνει γεωγραφικές και οικονομικές ανισότητες.
- **sfworkershh (Εργαζόμενα Μέλη):** Περισσότερο σταθερό εισόδημα αυξάνει την αγοραστική δύναμη.
- **urban (Αστικότητα):** Αστικές και αγροτικές περιοχές έχουν διαφορετικά πρότυπα κατανάλωσης.
- **educ\_max (Εκπαίδευση):** Υψηλότερη μόρφωση συνδέεται με καλύτερες οικονομικές προοπτικές.
- **dweltyp & sewer (Κατοικία – Υποδομές):** Η ποιότητα στέγασης και οι υποδομές δείχνουν οικονομική ευημερία.
- **sector1d (Τομέας Απασχόλησης):** Ο κλάδος εργασίας επηρεάζει το επίπεδο δαπανών.
- **num\_children18 (Παιδιά):** Περισσότερα παιδιά μειώνουν την κατά κεφαλήν διαθεσιμότητα πόρων.
- **consumed2600 / 4700:** Κατανάλωση μη βασικών αγαθών διαχωρίζει τα οικονομικά στρώματα.

## Προτάσεις Βελτίωσης

Η προσθήκη δεδομένων σχετικά με την κατοχή συγκεκριμένων περιουσιακών στοιχείων (π.χ. ηλεκτρικές συσκευές, οχήματα) ή πληροφοριών για το τοπικό κόστος ζωής θα μπορούσε να μειώσει το σφάλμα πρόβλεψης.

Επίσης, μια πιθανή βελτίωση θα ήταν η δημιουργία νέων χαρακτηριστικών (feature engineering), όπως η αναλογία εργαζομένων προς το συνολικό μέγεθος του νοικοκυριού.